The Regularization Challenge

Regularización de una red densa para reconocimiento de imágenes

Gómez Hernández, Marco
Miralles Retuerto, Pablo
Sánchez Carmona, Germán

Universidad Politécnica de Madrid
Máster Universitario en Inteligencia Artificial
Visión por Computador

18 de octubre de 2026

Objetivo y restricciones

Objetivo

Mejorar la generalización del modelo del challenge anterior mediante regularización para reducir el sobreajuste.

- Técnicas estudiadas: penalización L2, Dropout, Batch Normalization y data augmentation.
- Arquitectura clasificadora exclusivamente densa: **sin CNN ni transfer learning**.
- Comparar accuracy, entropía cruzada, métricas macro y brecha entre entrenamiento y validación.

Una brecha menor no basta: también debe valorarse el resultado de validación.

Modelo y datos de partida

Baseline de esta fase

Entrada $32 \times 32 \times 3 \rightarrow$ Flatten $\rightarrow$ Dense(256, ReLU) $\rightarrow$ Dense(128, ReLU) $\rightarrow$ Dense(64, ReLU) $\rightarrow$ Dense(13, Softmax).

- Reducción por promedio, píxeles normalizados a $[0, 1]$ y precarga en memoria.
- 13 clases; **16.871** imágenes de entrenamiento y **1.875** de validación. Reparto 90/10, `random_state=1`.
- SGD: LR inicial 10^{-3}, momentum 0,9, Nesterov y `clipnorm=1`.
- Entropía cruzada categórica; batch 8; checkpoint por mayor `val_accuracy`.
- Baseline histórico: accuracy **60,853 %**, recall macro 53,368 %, precisión macro 55,068 %.

Es la versión mejorada adaptada a esta fase; no es la entrada de 224×224 de los primeros experimentos ffNN.

Primera exploración: técnicas aisladas

Exp.	Cambio	Acc. (%)	Recall	Precisión
01	L2 10^{-4} en las tres capas ocultas	59,200	52,135	53,786
02	L2 más suave: 10^{-5}	59,947	52,368	55,729
03	Dropout 0.2 tras las tres capas ocultas	60,160	53,134	56,264
04	Dense $\rightarrow$ BN $\rightarrow$ ReLU; batch 8	55,680	51,671	50,081
05	Misma red BN; batch 32	56,853	51,255	53,389
06	Volteos horizontales y verticales antes de Flatten	57,600	50,085	51,623
07	Dropout 0.1	57,707	50,724	54,001

- Máximo 100 épocas; paciencia LR 5 y EarlyStopping 10. Sin semilla global de entrenamiento fijada.
- Ninguna supera al baseline histórico; **Dropout 0.2 es la más prometedora** en esta exploración.
- Estas ejecuciones no aíslan totalmente técnica, inicialización y calendario adaptativo del LR.

Mejorar el protocolo antes de combinar técnicas

- **Experimento 08:** semilla 42 y operaciones deterministas. Misma inicialización; comparar paciencias 5/10 frente a 10/20 con Dropout 0.1.
- Accuracy: **60,373 %** $\rightarrow$ **61,013 %**, doce aciertos más. Coincidencia exacta de métricas hasta la primera divergencia del LR.
- **Experimentos 09–10:** comparar tasas 0 / 0.1 / 0.2 con semilla y protocolo común. Máximo de épocas 100 $\rightarrow$ 200.
- Evaluar train y validación **con el mismo checkpoint y en inferencia**: Dropout desactivado en ambos.

Lo que no mide la brecha de fit

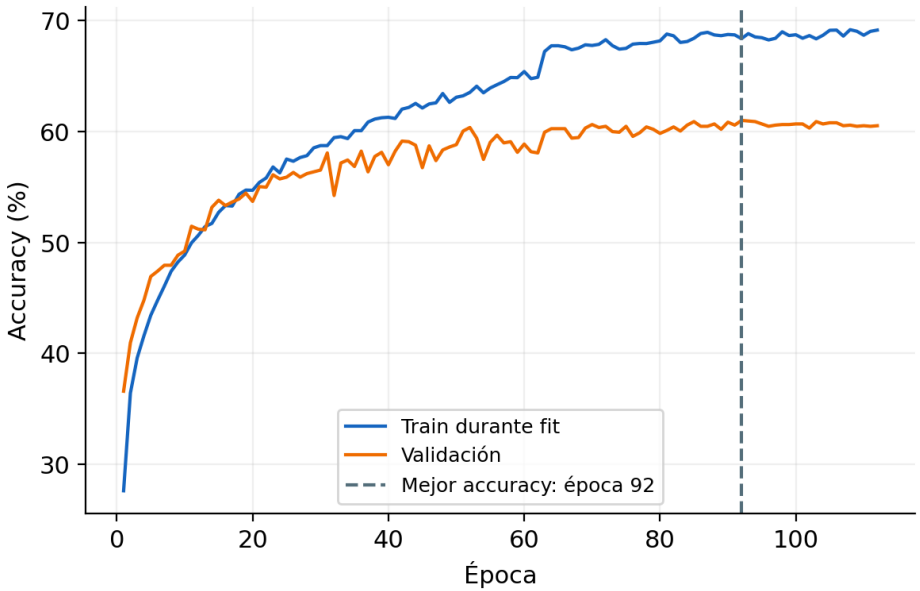
Durante fit, train usa Dropout y pesos cambiantes; validación no. Su diferencia no equivale a evaluar ambos conjuntos con el modelo congelado.

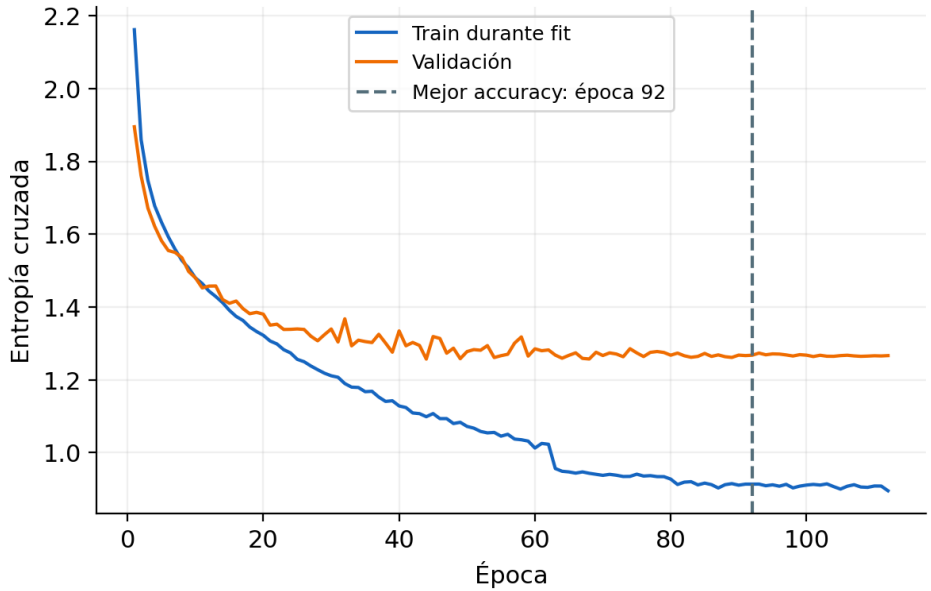
Comparación controlada: máximo 200 épocas

	Sin Dropout	**Dropout 0.1**	**Dropout 0.2**
Accuracy validación (%)	59,573	**61,013**	60,907
Entropía cruzada	1,2917	1,2677	**1,2308**
Accuracy train (%)	68,905	74,542	71,993
Brecha inferencia (pp)	9,332	13,529	11,087
Mejor época / ejecutadas	60 / 80	92 / 112	107 / 127

- Dropout 0.1: **27 aciertos más** que el control (+1,440 pp).
- Dropout 0.2: **25 aciertos más** (+1,333 pp); gana siete al superar 100 épocas.
- Entre las tasas: **solo dos imágenes**. Una semilla no demuestra superioridad general.

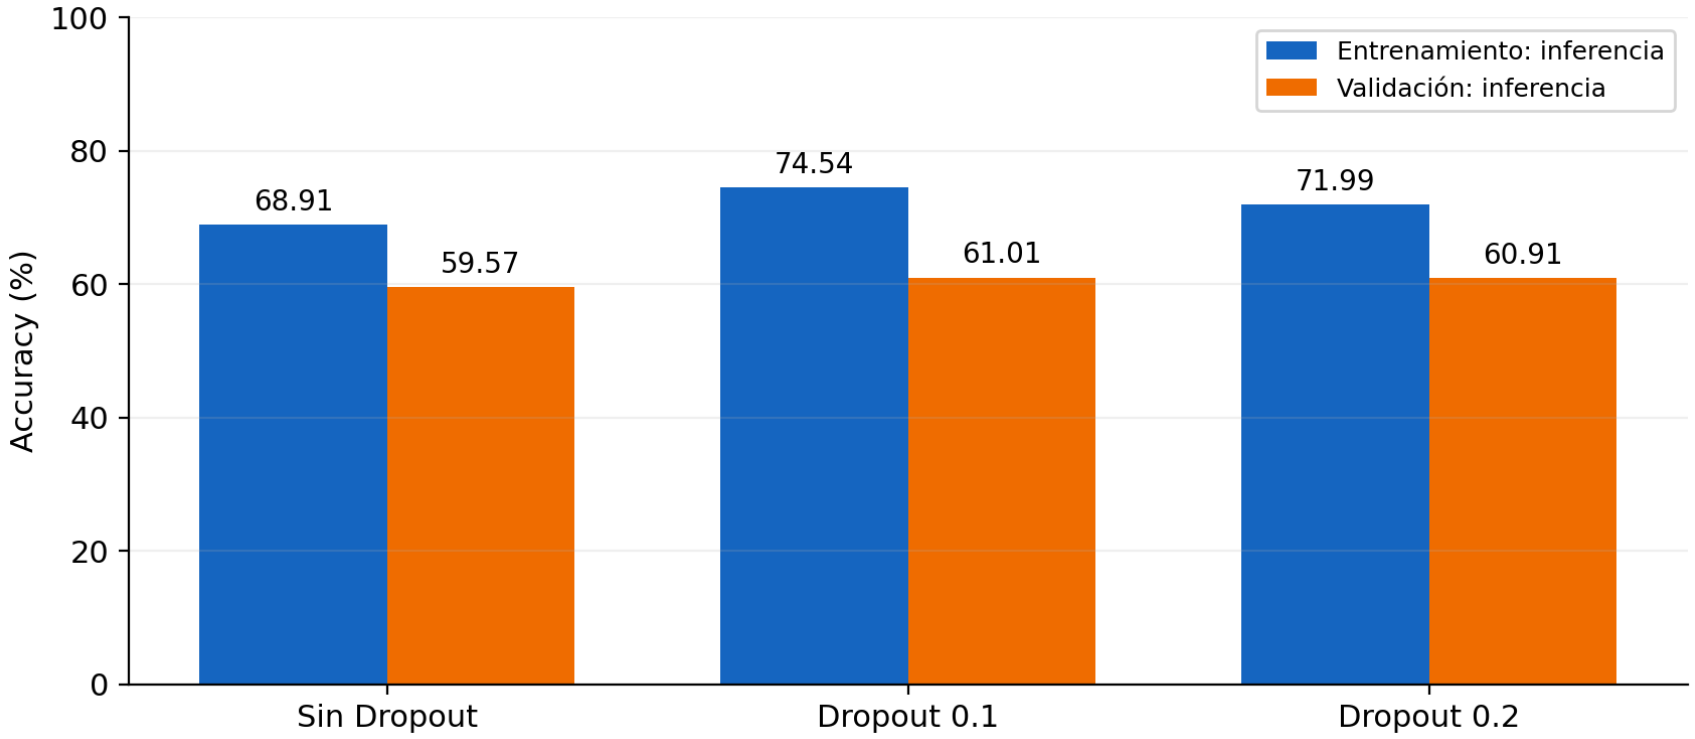
Entrenamiento del modelo final: Dropout 0.1





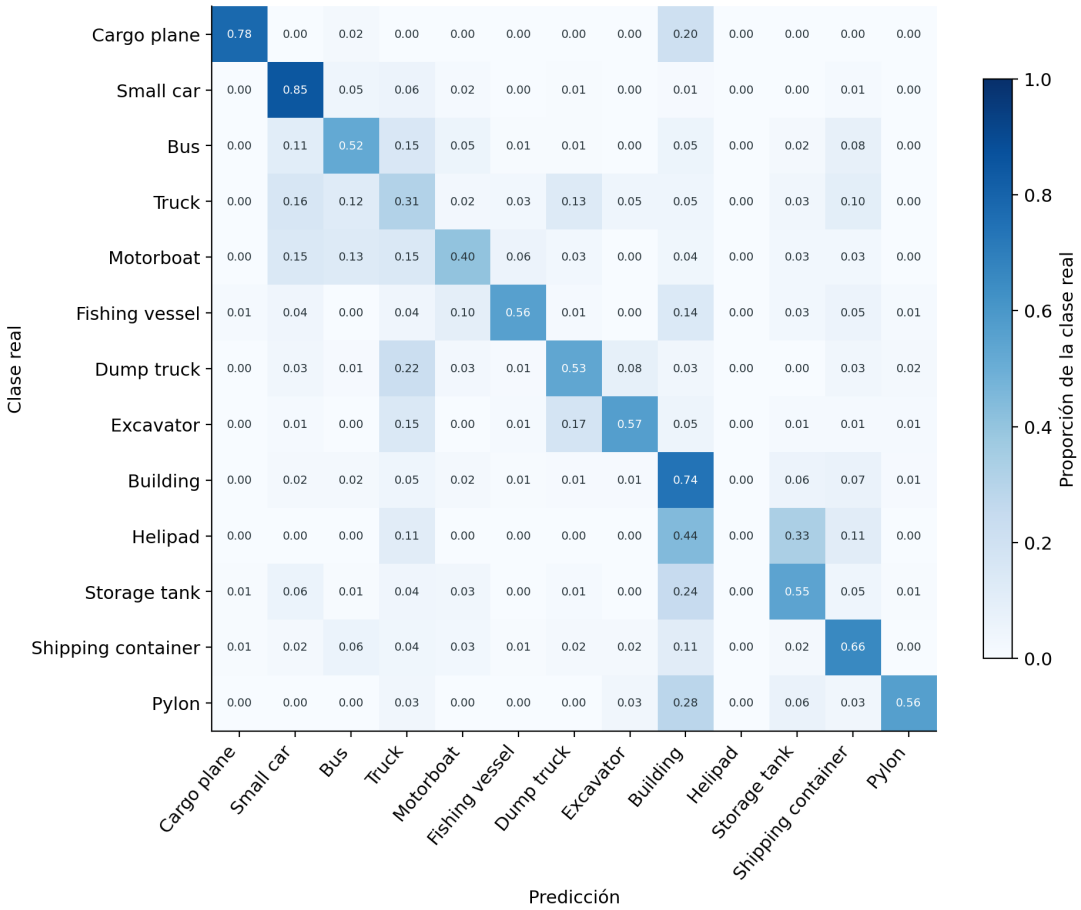
Mejor época: **92**; parada: **112**. Las curvas de train se midieron con Dropout activo. La evaluación posterior sin Dropout alcanza 74,542 % en train y 61,013 % en validación.

Generalización bajo condiciones comparables



Cada configuración se evalúa con su propio mejor checkpoint. Dropout mejora la validación del control, aunque la brecha no es menor: el control también ajusta menos el entrenamiento.

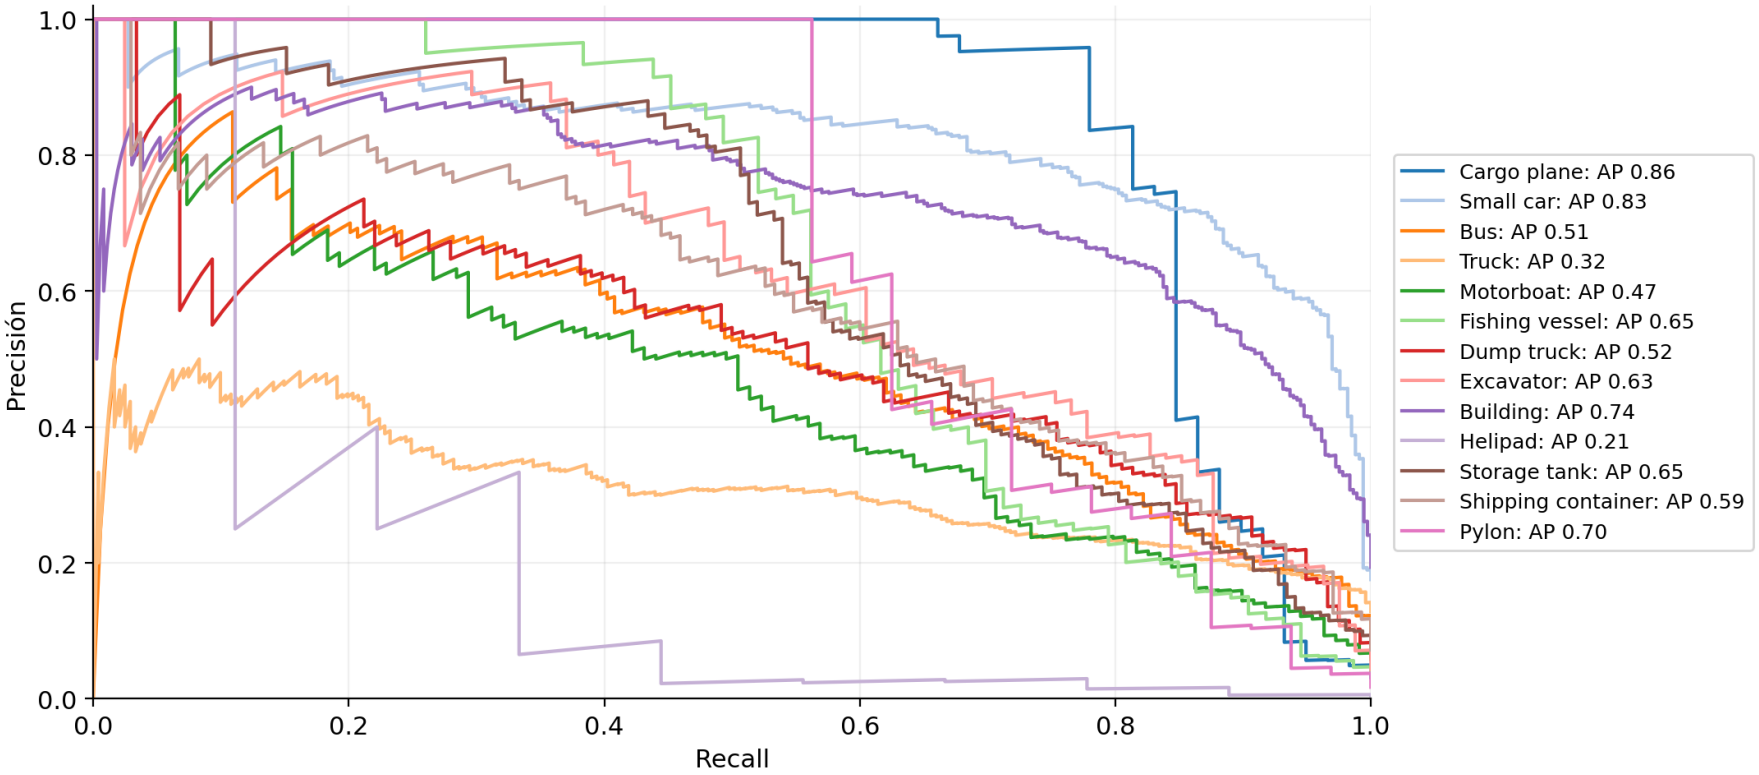
Modelo final: matriz de confusión



- Small car: recall **84,80 %**.
- Cargo plane: recall **77,97 %**.
- Truck: recall **31,12 %**.
- Helipad: recall **0 %**.

Filas: clase real.
Columnas: predicción.

Modelo final: curvas precision–recall



AP resume cada curva y no equivale a la precisión del argmax. La prevalencia de referencia depende de la clase. Los valores de AP se incorporarán tras ejecutar el notebook.

Última prueba: combinar Dropout y L2

Experimento 11

Dropout 0.1 + L2 10^{-5} en las tres capas ocultas. Misma semilla, inicialización y protocolo del experimento 10.

	Dropout 0.1	**Dropout + L2**
Accuracy (%)	**61,013**	60,907
Recall macro (%)	**54,137**	53,869
Precisión macro (%)	**56,636**	56,429
Entropía cruzada sin L2	**1,2677**	1,2692

- Dos aciertos menos y brecha prácticamente igual: no se adopta la combinación.
- La loss total incluye una penalización L2 de 0,009408; se compara la entropía cruzada por separado.

Conclusiones y selección final

Candidato seleccionado: Dropout 0.1, experimento 10

Accuracy **61,013 %**; recall macro **54,137 %**; precisión macro **56,636 %**. Modelo denso, 828.685 parámetros.

- Mejora al control con semilla común en **1,440 puntos**. Dropout 0.2 es alternativa por su menor pérdida.
- BN, L2 y volteos no mejoraron las configuraciones de referencia en las pruebas realizadas. La combinación final tampoco aportó una mejora adicional.
- Persisten errores en clases minoritarias: Helipad no se resuelve con estas regularizaciones.
- Limitación: una partición y una semilla en las comparaciones controladas; repetir varias semillas sería el siguiente paso para comprobar robustez.

Se cierra la experimentación prevista. Las métricas son de validación: generar predicciones no proporciona una puntuación de test.