The Regularization Challenge

Regularización de una red densa para reconocimiento de imágenes

Gómez Hernández, Marco
Miralles Retuerto, Pablo
Sánchez Carmona, Germán

Universidad Politécnica de Madrid
Máster Universitario en Inteligencia Artificial
Visión por Computador

18 de octubre de 2026

Objetivo y punto de partida

Reducir el sobreajuste mediante regularización

Red densa: **sin CNN ni transfer learning**. Técnicas: L2, Dropout, Batch Normalization y aumentación.

- Entrada RGB 32×32, normalizada a $[0, 1]$ y precargada.
- Flatten $\rightarrow$ Dense(256, ReLU) $\rightarrow$ Dense(128, ReLU) $\rightarrow$ Dense(64, ReLU) $\rightarrow$ Dense(13, Softmax).
- **16.871** imágenes de train y **1.875** de validación; reparto fijo 90/10.
- SGD: LR 10^{-3}, momentum 0.9 y Nesterov; batch 8.
- Baseline histórico: **60,853 %** de accuracy en validación.

Primera exploración: técnicas aisladas

Exp.	Cambio	Acc. validación (%)
01	L2 10^{-4} en las capas ocultas	59,200
02	L2 más suave: 10^{-5}	59,947
03	Dropout 0.2 tras cada capa oculta	**60,160**
04	Dense $\rightarrow$ BN $\rightarrow$ ReLU; batch 8	55,680
05	Misma red BN; batch 32	56,853
06	Volteos horizontales y verticales	57,600
07	Dropout 0.1	57,707

- **Dropout es la opción más prometedora** de esta exploración.
- Sin semilla global fijada: las diferencias también pueden depender de inicialización y callbacks.

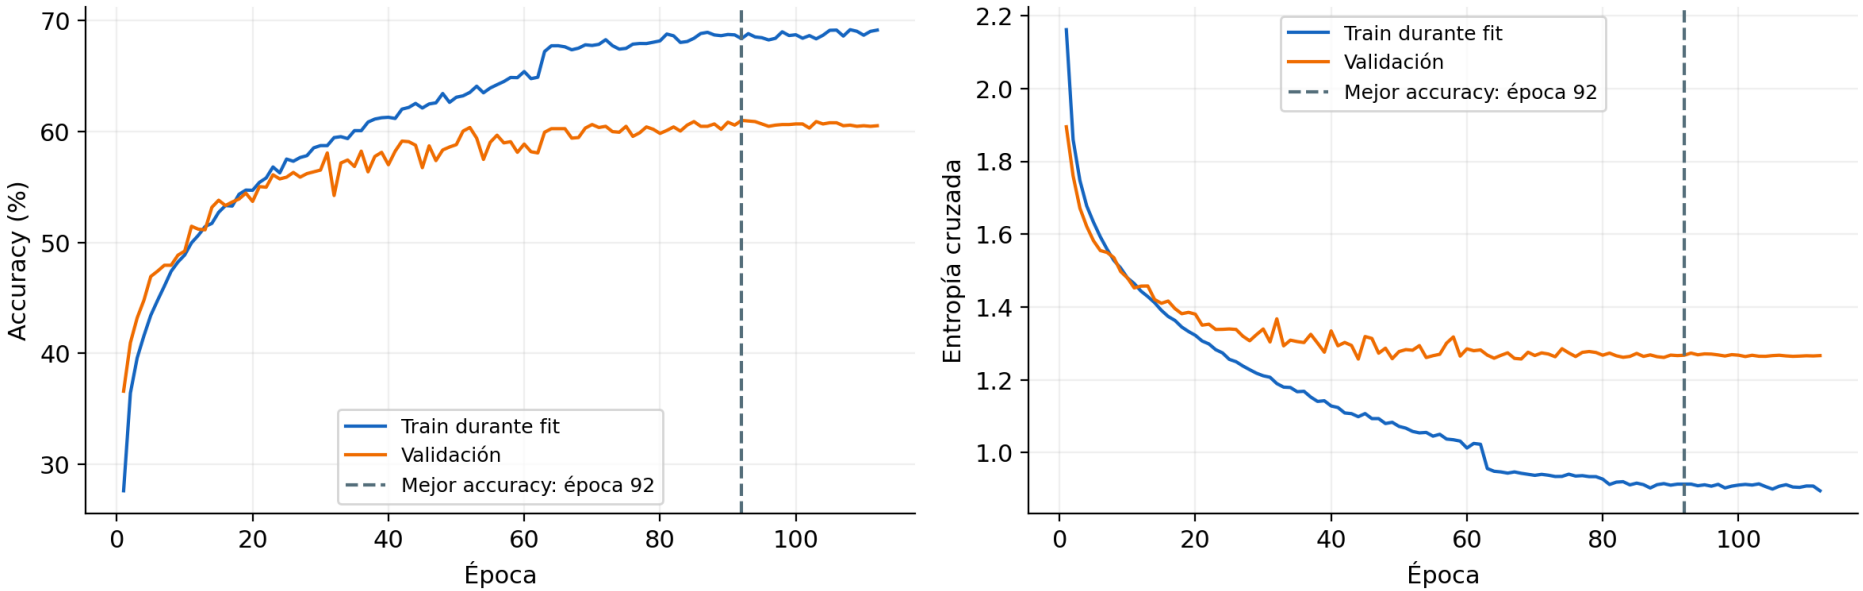
Comparación controlada: experimentos 08–10

- Semilla **42**, mismos pesos iniciales y máximo **200 épocas**.
- Paciencias LR/parada: **10/20**. Evaluación del mejor checkpoint con Dropout desactivado en train y validación.

	Sin Dropout	**Dropout 0.1**	**Dropout 0.2**
Accuracy validación (%)	59,573	**61,013**	60,907
Entropía cruzada	1,2917	1,2677	**1,2308**
Brecha inferencia (pp)	9,332	13,529	11,087
Mejor época / ejecutadas	60 / 80	92 / 112	107 / 127

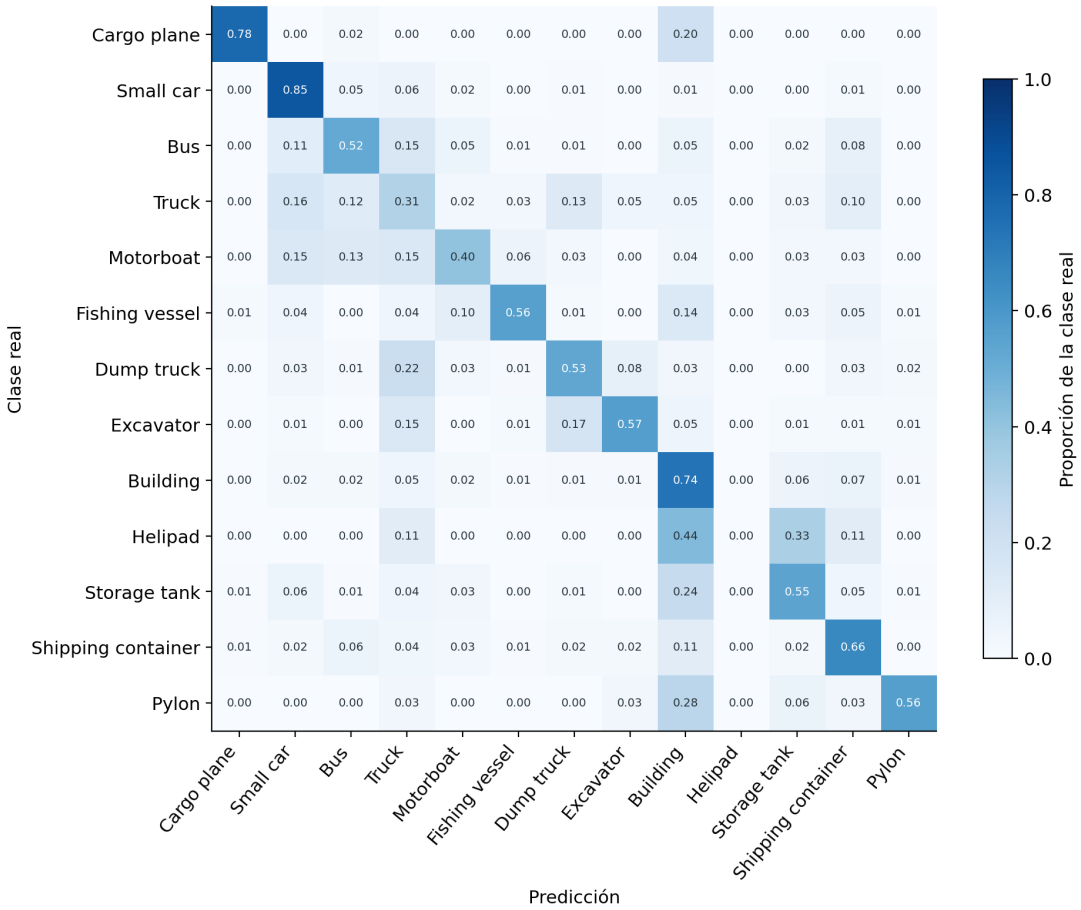
- Dropout 0.1 gana **27 aciertos** al control (+1,440 pp).
- Entre tasas solo hay **dos imágenes**; 0.2 obtiene menor pérdida.

Mejor modelo en validación: Dropout 0.1



Mejor época: **92**; parada: **112**. Las curvas de train se midieron con Dropout activo. La evaluación posterior sin Dropout alcanza 74,542 % en train y 61,013 % en validación.

Mejor modelo en validación: matriz de confusión



- Small car: recall **84,80 %**.
- Cargo plane: recall **77,97 %**.
- Truck: recall **31,12 %**.
- Helipad: recall **0 %**.

Filas: clase real.
Columnas: predicción.

Última prueba: combinar Dropout y L2

Experimento 11

Dropout 0.1 + L2 10^{-5} en las tres capas ocultas. Misma semilla, inicialización y protocolo del experimento 10.

	Dropout 0.1	**Dropout + L2**
Accuracy (%)	**61,013**	60,907
Recall macro (%)	**54,137**	53,869
Precisión macro (%)	**56,636**	56,429
Entropía cruzada sin L2	**1,2677**	1,2692

- Dos aciertos menos y brecha prácticamente igual: no mejora la validación de Dropout solo.
- Se envía a Codabench como combinación final; su resultado externo se muestra a continuación.

Resultados externos: Codabench

Evaluación de los tres archivos de predicciones enviados

Métricas de Codabench en porcentaje, redondeadas a dos decimales. Son resultados externos, distintos de la validación local.

Envío	**Accuracy**	**Precisión**	**Recall**
Baseline	50,53	53,77	42,81
Exp. 08: Dropout 0.1	52,22	**56,54**	46,74
Exp. 11: Dropout + L2	**52,39**	56,39	**47,21**

- **El experimento 11 es el publicado en la clasificación.**
- Mejor accuracy de los envíos: +1,86 puntos frente al baseline; +0,17 frente al 08.

Conclusiones

Resultado publicado: experimento 11, Dropout 0.1 + L2

Codabench: accuracy **52,39 %**, precisión **56,39 %** y recall **47,21 %**.

- **Dropout fue la regularización más útil** en las comparaciones controladas.
- La combinación no mejora la validación local, pero obtiene la **mayor accuracy externa de los tres envíos**.
- Mejor validación local: Dropout 0.1, **61,013 %**. Las gráficas anteriores corresponden a este modelo, no al envío 11.
- Persisten limitaciones: Helipad tiene recall 0 % en validación; una partición y una semilla no bastan para demostrar superioridad general.